

Plan de cours N° : 1363

Durée : 3 jours (21h)

RAG et Fine Tuning d'un LLM

PARTICIPANTS / PRE-REQUIS

Chercheurs et ingénieurs en IA souhaitant optimiser et personnaliser des LLM

Bonne connaissance du langage Python et avoir quelques connaissances de base en Deep Learning et NLP

OBJECTIFS PEDAGOGIQUES

Décrire le fonctionnement et les limites d'une LLM. Expliquer les concepts clés du RAG. Créer un Pipeline RAG avec LangChain. Expliquer les techniques de fine tuning sur un LLM. Evaluer et optimiser les performances d'un modèle. Déployer un modèle en production.

MOYENS PEDAGOGIQUES

Tour de table au début de chaque formation pour définir les objectifs de chaque participant,

Alternance entre apports théoriques (en moyenne 30%) et exercices pratiques (en moyenne 70%),

Utilisation de cas concrets issus de l'expérience professionnelle de nos formateurs,

Remise d'un support de cours,

Assistance post-formation d'une durée de 1 an sur le contenu de la formation via notre adresse mail dédiée formateurs@atp-formation.com

MOYENS PERMETTANT LE SUIVI DE L'EXECUTION ET DES RESULTATS

Positionnement préalable oral ou écrit,

Evaluation des acquis tout au long de la formation par des exercices de synthèse,

Attestation de stage remise à chaque apprenant, avec son niveau d'acquisition pour chaque objectif pédagogique,

Feuille de présence signée par demi-journée,

Questionnaire de satisfaction pour évaluer la qualité de l'enseignement,

En option : passage certification possible selon les thématiques

MOYENS TECHNIQUES EN PRESENTIEL

Accueil des stagiaires dans une salle dédiée à la formation, équipée d'ordinateurs, d'un vidéo projecteur d'un tableau blanc

MOYENS TECHNIQUES DES CLASSES A DISTANCE

Grâce à un logiciel comme Teams, suivez une formation en temps réel et entièrement à distance. Lors de la classe en ligne, les apprenants interagissent et communiquent entre eux et avec le formateur.

Nous vous conseillons très fortement l'utilisation de votre webcam et de disposer d'un double écran.

Pour toute question avant et pendant le parcours, une assistance technique et pédagogique est à disposition par téléphone au 04.76.41.14.20..

ORGANISATION

Les cours ont lieu de 9h00-12h30 13h30-17h00 (adaptable à la demande).

PROFIL FORMATEUR

Nous recrutons méticuleusement nos formateurs selon 3 critères : expertise, pédagogie et agilité.

ACCESSIBILITE

Les personnes atteintes de handicap souhaitant suivre nos formations sont invitées à nous contacter directement, afin d'étudier ensemble les possibilités d'organisation.

MISE A JOUR

02/06/2025

Siège social :

31 avenue du Granier
38240 MEYLAN

Agences :

170 rue de Chatagnon
38430 Moirans

Le Thélème

1501/1503 route des Dolines
06560 Valbonne

Plan de cours N° : 1363

Durée : 3 jours (21h)

RAG et Fine Tuning d'un LLM

INTRODUCTION A L'IA GENERATIVE ET AUX LLM

- Rappels sur le Deep Learning
- Rappels sur l'architecture Transformer
- Forces et faiblesses d'un LLM
- Les principaux LLM à notre disposition
- Première utilisation de ces modèles
- Que sont le RAG (Retrieval Augmented Generation) et le Fine Tuning ?

LE RAG (RETRIEVAL AUGMENTED GENERATION)

- Les concepts clés du RAG
 - Qu'est-ce qu'un embedding (un plongement) ?
 - Word embedding VS Sentence embedding
 - Bases de données vectorielles
- Indexation des données
 - Chargement des données (PDF, Docx, Json, Web scraping,...)
 - La vectorisation des données (FAISS, ChromaDB, Weaviate)
 - Les modèles d'embedding (Mistral-Embed, OpenAI, Sentence Transformers)
- Mécanisme de récupération des données
 - Recherche sémantique
 - Similarité cosinus, re-ranking
- Génération augmentée
 - Techniques de prompt engineering
 - Fusion des données récupérées avec un LLM
 - Mise en oeuvre d'une interface graphique avec Gradio
- Cas d'usage et enjeux stratégiques
 - Applications du RAG dans l'industrie
 - Mise en oeuvre agents conversationnels avec une base de connaissances personnalisée

MISE EN OEUVRE D'UN PIPELINE POUR SON RAG

- Pourquoi utiliser des Tool Chains ?
- Les principaux outils de Pipeline
 - LangChain
 - LlamaIndex
 - Haystack
- Création d'un Pipeline RAG avec LangChain
 - Configuration des outils
 - Intégration des modèles de langage
 - Exécution et test du Pipeline
- Agents LLM et logique ReAct
 - Qu'est-ce qu'un agent LLM ?
 - Qu'est-ce que la Logique ReAct (Reasoning and Acting) ?
 - Exemples d'agents avec LangChain

REALISER UN FINE TUNING

- Fine Tuning Complet VS Fine Tuning léger (LoRA, QLoRA...)
- Préparation des données
 - Nettoyage et structuration des données
 - Formats de fichiers utilisables (JSONL, HF datasets...)
 - Stratégies d'annotation et de génération de prompts
- Augmentation des données
- Mise en oeuvre du Fine Tuning
 - Les API utilisables
 - Gestion des ressources GPU
- Evaluation et métriques de performance
- Distillation de modèles

OPTIMISATION ET DEPLOIEMENT

- Quantization et compression d'un modèle
- Déploiement d'un modèle fine tuned
 - Le logiciel Gradio
 - Le déploiement en API via FastAPI
 - Les logiciels Jan.ai et Ollama

FINE TUNING VS RAG

- Comparaison entre les deux techniques
- Combiner les approches pour améliorer les performances